



UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



SHAPLEYHO METÓDA PRIRAĐOVANIA
ZÁSLUH PRE ALGORITMUS DREAMER V
ÚLOHÁCH S TERMINÁLNOU ODMENOU

Diplomová práca

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



SHAPLEYHO METÓDA PRIRAĐOVANIA ZÁSLUH PRE ALGORITMUS DREAMER V ÚLOHÁCH S TERMINÁLNOU ODMENOU

Diplomová práca

Študijný program: Aplikovaná informatika
Študijný odbor: Aplikovaná informatika
Katedra: Katedra aplikovanej informatiky
Školiteľ: Mgr. Marek Šuppa

Čestne vyhlasujem, že som túto diplomovú prácu vypracoval samostatne s použitím uvedenej literatúry a pod odborným vedením vedúceho diplomovej práce.

Bratislava, 2026

.....
Bc. Aleksandr Bukhtoiarov

Pod'akovanie

Abstrakt

Jedným zo základných problémov posilňovaného učenia je credit assignment, teda určenie príspevku jednotlivých akcií k výslednej odmene. Tento problém je obzvlášť výrazný v úlohách s terminálnou odmenou, kde je celý epizód hodnotený jediným skalárnym signálom a priebežná spätná väzba chýba. V takýchto podmienkach algoritmus nedostáva informáciu o tom, ktoré akcie prispeli k výsledku pozitívne a ktoré negatívne, čo vedie k vysokej variancii gradientov a výrazne sťažuje učenie, najmä pri dlhých sekvenciách akcií.

Nedávno navrhnutá metóda SCAR (Shapley Credit Assignment for More Efficient RLHF) formuluje generovanie sekvencií ako kooperatívnu hru a využíva Shapleyho hodnoty na rozklad terminálnej odmeny na príspevky jednotlivých tokenov. V kontexte RLHF to umožňuje nahradiť jednu riedku odmenu hustou sekvenciou tokenových odmien, ktoré môžu byť použité na stabilnejšie a efektívnejšie doučenie veľkých jazykových modelov.

V tejto práci sa myšlienka Shapley-based credit assignment prenáša z RLHF do algoritmu Dreamer. Na rozdiel od RLHF, kde hodnotenie odmeny vyžaduje samostatný reward model natrénovaný na ľudských preferenciách, Dreamer už obsahuje učný model dynamiky prostredia a odmeny. To umožňuje vyhodnocovať kontrafaktuálne varianty trajektórií pomocou latentných imaginárnych rolloutov bez dodatočnej interakcie s reálnym prostredím.

Práca sa zameriava na textové a textovo-procedurálne úlohy, v ktorých agent vykonáva sekvenciu diskretných akcií (napríklad generovanie textu, operácie s pamäťou alebo volanie modulov) a odmenu dostáva až na konci epizódy. Po ukončení epizódy je terminálna odmena rozdelená medzi jednotlivé akcie pomocou Shapleyho samplovania. To sa realizuje odhadom očakávanej terminálnej odmeny pre viaceré modifikované varianty tej istej trajektórie, získané nahradením podmnožiny akcií bazálnou akciou, a ich vyhodnotením prostredníctvom latentných rolloutov modelu prostredia Dreamer. Výsledná sekvencia príspevkov akcií je následne použitá ako hustý signál odmeny na tréning politiky aj modelu dynamiky.

V experimentálnej časti je algoritmus Dreamer porovnaný v troch tréningových režimoch: s použitím iba terminálnej odmeny, s ručným reward shapingom a s rozkladom odmeny pomocou Shapleyho hodnôt. Hodnotenie sa zameriava na rýchlosť učenia,

stabilitu tréningu a kvalitu naučenej politiky, ako aj na vplyv počtu Shapleyho vzoriek a stratégie segmentácie akcií.

Kľúčové slová: posilňované učenie, modely sveta, Dreamer, credit assignment, Shapleyho hodnoty, terminálna odmena, RLHF

Obsah

1	Teoretické základy	2
2	Navrhovaná metóda	3
3	Implementácia	4
4	Experimenty	5
5	Záver	6

Zoznam obrázkov

Zoznam tabuliek

Označenia

Motivácia

Kapitola 1

Teoretické základy

Kapitola 2

Navrhovaná metóda

Kapitola 3

Implementácia

Kapitola 4

Experimenty

Kapitola 5

Záver

Literatúra

- [1] Jose A. Arjona-Medina, Michael Gillhofer, Michael Widrich, Thomas Unterthiner, Johannes Brandstetter, and Sepp Hochreiter. RUDDER: Return decomposition for delayed rewards. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [2] Paul F. Christiano, Jan Leike, Tom Brown, Miljan Martic, Shane Legg, and Dario Amodei. Deep reinforcement learning from human preferences. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [3] Danijar Hafner, Timothy Lillicrap, Jimmy Ba, and Mohammad Norouzi. Dream to control: Learning behaviors by latent imagination. In *International Conference on Learning Representations (ICLR)*, 2020.
- [4] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse domains through world models. *arXiv preprint arXiv:2301.04104*, 2023.
- [5] Anna Harutyunyan, Will Dabney, Thomas Mesnard, Mohammad Azar, Bilal Piot, Nicolas Heess, Hado van Hasselt, Greg Wayne, Satinder Singh, Doina Precup, and Rémi Munos. Hindsight credit assignment. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [6] Authors of AgeMem. AgeMem: Agentic memory with step-level grpo, 2026. Bibliographic details to be verified against the published version.
- [7] Authors of MemAct. MemAct: Memory-as-action with dynamic context policy optimization, 2025. Bibliographic details to be verified against the published version.
- [8] Authors of SCAR. SCAR: Shapley credit assignment for more efficient RLHF. *arXiv preprint arXiv:2505.20417*, 2025. Bibliographic details to be verified against the published version.
- [9] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray,

- et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [10] Benedek Rozemberczki, Lauren Watson, Péter Bayer, Hao-Tsung Yang, Olivér Kiss, Sebastian Nilsson, and Rik Sarkar. The Shapley value in machine learning. *arXiv preprint arXiv:2202.05594*, 2022.
- [11] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. In *arXiv preprint arXiv:1707.06347*, 2017.
- [12] Erik Štrumbelj and Igor Kononenko. Explaining prediction models and individual predictions with feature contributions. *Knowledge and Information Systems*, 41(3):647–665, 2014.
- [13] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2nd edition, 2018.